

Chapitre 2: Les modèles de recherche d'information

Dr. Anwer Kalghoum

Qu'est ce qu'un modèle de RI ?

- Un modèle est une abstraction d'un processus (ici recherche d'info)
- Les modèles de RI peuvent décrire
 - Le processus de mesure de pertinence : comment les documents sont sélectionnés et triés
 - L'utilisateur : besoin en information, interaction
- Les modèles de RI se distinguent par le principe d'appariement (matching) :
 - appariement exact /approché (Exact /Best matching)

Appariement exact /Appariement approché

□ Appariement exact

✓ L'ensemble des documents respectant exactement la requête sont sélectionnés, **mais pas ordonné**.

✓ Appariement approché

✓ Les documents sont sélectionnés selon un degré de pertinence (similarité/ probabilité) vis-à-vis de la requête et sont ordonné


Modèles de RI

Les différents modèles de la RI

- ✓ Modèle booléen / Modèle booléen étendu / Modèle Flou
- ✓ Modèle vectoriel
- ✓ Modèle probabiliste
- ✓ Modèle connexionniste (réseaux de neurones)
- ✓ Modèle d'inférence (réseau d'inférence bayésien)
- ✓ Modèle LSI (Latent Semantic Indexing)
- ✓ Modèle de langage

Modèles de RI

Typologie de modèle des SRI :



Le Modèle Booléen

Le Modèle Booléen

Le **modèle booléen** ou **logique**, est historiquement le premier modèle de RI. Le modèle booléen de base (**strict**) repose sur la **théorie des ensembles** et la **logique des propositions**.

- Un document est représenté un ensemble de termes:

$$\text{--Ex : } d1(t_1, t_2, t_5); \quad d2(t_1, t_3, t_5, t_6); \quad d3(t_1, t_2, t_3, t_4, t_5)$$

- Une requête est un ensemble de mots avec des opérateurs booléens : AND ($\wedge$), OR ($\vee$), NOT ($\neg$)

$$\text{--Ex: } q = t_1 \wedge (t_2 \vee \neg t_3)$$

- **Appariement Exact** basé sur la présence ou l'absence des termes de la requête dans les documents

Les concepts du modèle booléen

Le modèle de recherche booléen est défini par un quadruplet (T , Q , D , F) Où:

- T : Ensemble des termes d'indexation

$$T = \{t_1, t_2, \dots, t_n\}$$

- D : Ensemble des documents de la collection:

$$D = \{d_1, d_2, \dots, d_m\}, \text{ ex: } d_1 = (t_1, t_2, t_5);$$

- Q : Ensemble de requêtes booléennes

$$Q = \{q_1, q_2, \dots, q_k\}, \text{ ex: } q = t_1 \wedge (t_2 \vee \neg t_3);$$

- F : Fonction de pertinence définie par :

$$F: D \times Q \longrightarrow \{0, 1\}$$

$$F(d, t) = \begin{cases} 1 & \text{si } t \in d \\ 0 & \text{sinon} \end{cases}$$

Modèle de documents

Pour le modèle booléen de base, un **document** est représenté par ensemble de **termes** indépendants noté:

$d(t_1, t_2, \dots, t_n)$

Exemple :

soient 3 documents:

$d_1(t_1, t_2, t_5); d_2(t_1, t_3, t_5, t_6); d_3(t_1, t_2, t_3, t_4, t_5)$

Modèle de requête

- Modèle de requête Pour l'utilisateur, Une requête est un ensemble de termes reliés avec des opérateurs booléens :

AND ($\wedge$), OR($\vee$), NOT ($\neg$)

- L'ensemble de requêtes est noté: $Q = \{q_1, q_2, \dots, q_k\}$ ou k représente le nombre de requêtes.
- Exemple : soit la requête q : $q = t_1 \wedge (t_2 \vee \neg t_3)$

Modèle de requête

Une requête est le plus souvent formulée dans un langage de requête spécifique au système. Plusieurs types de langage de requêtes peuvent être utilisés :

Simple

- ensemble de mots ou sac de termes: Bag of words
- une phrase ou un paragraphe en langage naturel ;


Complexes

expressions booléennes ; expressions régulières ; langage structuré précisant la valeur d'attributs tels que les noms d'auteurs, les mots du titre etc...

Modèle de requête

Une requête est une expression booléenne qui peut se modéliser avec **un arbre** où **les feuilles** sont **des termes**, et les nœuds internes sont des opérateurs AND ($\wedge$), OR ($\vee$), NOT ($\neg$).

Par Exemple : la requête $q = (A \text{ et } B) \text{ ou } C$ est représentée par l'arbre de la figure suivante:



Principe d'Appariement du Modèle Booléen

- Avec le modèle Booléen, le module de recherche mis en œuvre consiste à **effectuer des opérations sur l'ensemble de documents** afin de **réaliser un appariement exact** avec l'équation de la requête.
- **L'appariement exact est basé sur la présence ou l'absence des termes** de la requête dans les documents.

Appariement pour le Modèle Booléen

- Appariement Exact est basé sur la présence ou l'absence des termes de la requête dans les documents.
- À cette étape d'Appariement, le modèle booléen permet de calculer la fonction de pertinence appelée également **score de similarité** ou **Relevance Status Value (RSV)** pour un couple (document, requête). Cette mesure est notée **RSV (di, qj)** et retourne **le score de similarité** du document **di** par rapport à la requête **qj**.
- La correspondance **RSV(d, q)** entre une requête et un document est déterminée de la façon suivante:

$$R(d, t_i) = 1 \text{ si } t_i \in d; 0 \text{ sinon.}$$

$$R(d, q_1 \wedge q_2) = 1 \text{ si } R(d, q_1) = 1 \text{ et } R(d, q_2) = 1; 0 \text{ sinon.}$$

$$R(d, q_1 \vee q_2) = 1 \text{ si } R(d, q_1) = 1 \text{ ou } R(d, q_2) = 1; 0 \text{ sinon.}$$

$$R(d, \neg q_1) = 1 \text{ si } R(d, q_1) = 0; 0 \text{ sinon.}$$

Le score de similarité $RSV(d,q)$

- La mesure $RSV(d,q)$ est une fonction de correspondance (de similarité, de similitude) entre **un document et une requête**.
- Dans le modèle booléen, tous les documents qui **satisfont** une requête sont retrouvés (généralement **classés** dans un **ordre chronologique**).
- Ils ne sont pas classés selon leur pertinence. Cela est dû au fait qu'un document satisfait une requête ou ne la satisfait pas (1 ou 0).

Exemples 1 :

Requête

$$q = t_1 \wedge (t_2 \vee \neg t_3)$$

Documents

$$d1(t_1, t_2, t_5); \quad d2(t_1, t_3, t_5, t_6); \quad d3(t_1, t_2, t_3, t_4, t_5)$$

Calculer la correspondance :

$$R(d1, q) = ?$$

$$R(d2, q) = ?$$

$$R(d3, q) = ?$$

Correction exemple 1

- Document représenté par : $d1(t1, t2, t5)$
- Requête représentée par : $q = t1 \wedge (t2 \vee \neg t3)$
- Traiter la requête: Calculer la correspondance : $RSV(d1, q) = ?$

$RSV(d1, q) = RSV(d1, t1 \wedge (t2 \vee \neg t3)) = ?$ avec

$RSV(d1, t1) = 1$

$RSV(d1, t2) = 1$

$RSV(d1, \neg t3) = 1$

$RSV(d1, t2 \vee \neg t3) = 1$

$RSV(d1, 1 \wedge 1) = 1$

Décision (Résultat): Le document $d1$ correspond à la requête q .

donc $RSV(d1, q) = RSV(d1, t1 \wedge (t2 \vee \neg t3)) = 1$

Correction exemple 1

- Document représenté par : $d2(t1, t3, t5, t6)$;
- Requête représentée par : $q = t1 \wedge (t2 \vee \neg t3)$

Traiter la requête: Calculer la correspondance : $RSV(d2, q) = ?$

$RSV(d2, q) = RSV(d2, t1 \wedge (t2 \vee \neg t3)) = ?$ avec

$RSV(d2, t1) = 1$

$RSV(d2, t2) = 0$

$RSV(d2, \neg t3) = 0$

$RSV(d2, t2 \vee \neg t3) = 0$

$RSV(d2, 1 \wedge 0) = 0$

Décision (Résultat): Le document $d2$ ne correspond à la requête q .

donc $RSV(d2, q) = RSV(d2, t1 \wedge (t2 \vee \neg t3)) = 0$

Correction exemple 1

- Document représenté par : $d3(t1, t2, t3, t4, t5)$
- Requête représentée par : $q = t1 \wedge (t2 \vee \neg t3)$

Traiter la requête: Calculer la correspondance : $RSV(d3, q) = ?$

$RSV(d3, q) = RSV(d3, t1 \wedge (t2 \vee \neg t3)) =$ avec

$RSV(d3, t1) = 1$

$RSV(d3, t2) = 1$

$RSV(d3, \neg t3) = 0$

$RSV(d3, t2 \vee \neg t3) = 1$

$RSV(d3, 1 \wedge 1) = 1$

Décision (Résultat): Le document $d3$ correspond à la requête q .

donc $RSV(d3, q) = RSV(d3, t1 \wedge (t2 \vee \neg t3)) = 1$

Résultat final: Pour q , les documents $d1$ et $d3$ sont retournés.

Exemples 2 :

Supposons que nous ayons un ensemble de documents indexés dans une collection et que nous voulions effectuer des requêtes plus complexes avec des opérateurs booléens sur ces documents. Voici la liste des documents :

- **D1** : "voiture rouge et rapide"
- **D2** : "camion rouge"
- **D3** : "moto rapide"
- **D4** : "vélo rouge et rapide"

Maintenant, nous allons formuler des requêtes basées sur ces documents :

- q1** = voiture AND rouge
- q2** = (voiture OR camion) AND rapide
- q3** = (moto AND rapide) OR (vélo AND rouge)
- q4** = (camion OR moto) AND NOT rapide

Calculer les fonctions de correspondance RSV pour chaque requête ?

Avantages et inconvénients du Modèle Booléen

Les avantages

1. Ce modèle est simple à mettre en œuvre
2. la clarté conceptuelle des systèmes booléens

Les inconvénients

1. Tous les termes dans un document ou dans une requête étant pondérés de la même façon simple (0 ou 1) c'est à dire, indexation binaire
2. La sélection d'un document est basée sur une décision binaire
3. Pas d'ordre pour les documents sélectionnés
4. Formulation de la requête difficile pas toujours évidente pour beaucoup l'utilisateurs
5. Problème de collections volumineuses : le nombre de documents retournés peut être considérable

Modèle booléen étendu

Modèle booléen étendu

- Pour pallier à ces inconvénients, un modèle nommée « booléen étendu » a été proposée permettant de prendre en compte la **pondération** des termes (poids des termes).
- **Prendre en compte l'importance des termes dans les documents et dans la dans la requête.**

- **Deux modèles :**

- Modèle booléen étendu - extended boolean model
- Modèle flou- fuzzy based model (basé sur la logique floue)

Modèle booléen étendu

Extension du modèle booléen en intégrant des pondérations (les poids).

– Modèle de connaissances: $T = \{t_i\}$, $i \in [1, \dots, N]$

- Termes t_i qui indexent les documents

– Un document D est représenté par: $\mathbf{d} = t_1 \wedge t_2 \wedge \dots \wedge t_n$

- Une formule logique D (comme le modèle booléen)

• Une fonction $W_D : T \rightarrow [0,1]$, qui pour chaque terme de T donne le poids de ce terme dans D . Le poids vaut 0 pour un terme non présent dans le document.

– Requête: Une requête est un ensemble de mots avec des opérateurs booléens : AND ($\wedge$), OR ($\vee$), NOT ($\neg$).

Modèle booléen étendu

Soient deux documents D représentés par les termes d'indexation $T=\{t_1, t_2, \dots, t_8\}$

Les poids des termes dans d_1 et d_2 sont:

t_i	t_1	t_2	t_3	t_4	t_5	t_6	t_7	t_8
$W(t_i; D_1)$	0.5	0	0.7	1	0	0.3	0.6	0.8
$W(t_i; D_2)$	0.2	0.3	0.5	0	0.8	0.4	0.9	0

Modèle Booléen étendu

- Généralisation
 - Distance euclidienne à plusieurs dimensions Utilisation de la p-norm
- Considérons

- $\mathbf{d_j} = (w_{1j}, w_{2j}, \dots, w_{tj})$
- $\mathbf{q}$: requête composée de m termes ($t_1, t_2, \dots, t_m$)

$$R(d_j, q_{or}) = \left(\frac{w_{1j}^p + w_{2j}^p + \dots + w_{mj}^p}{m} \right)^{\frac{1}{p}}$$

$$R(d_j, q_{and}) = 1 - \frac{((1 - w_{1j})^p + (1 - w_{2j})^p + \dots + (1 - w_{mj})^p)^{\frac{1}{p}}}{m} = 1 - \left(\frac{(1 - x_1)^p + (1 - x_2)^p + \dots + (1 - x_m)^p}{m} \right)^{\frac{1}{p}}$$

$$R(d_j, q_{not}) = 1 - R(d_j, q)$$

avec p est une constante = 2, m = nombre des termes dans q

Plus **RSV est élevé (vers 1)** → plus le document est **pertinent** par rapport à la requête

Plus **RSV est faible (vers 0)** → moins le document est pertinent

Modèle Booléen étendu

- Si $p = 1$ alors (on retrouve le modèle vectoriel)
 - $RSV(d_j, q_{or}) = RSV(d_j, q_{and})$
- Si $p = \infty$ alors (modèle booléen)
 - $RSV(d_j, q_{or}) = \max (wx_j)$
 - $RSV(d_j, q_{and}) = \min (wx_j)$
- **$p = 2$** correspond à la distance euclidienne, semble être le meilleur choix

Donc $p = 2$

Modèle Booléen étendu

- Généralisation

- $\mathbf{d}_j = (w_{1j}, w_{2j}, \dots, w_{tj})$
- Si la requête et les documents sont pondérés $q(q_1, q_2, \dots, q_m)$

$$R(d_j, q_{or}) = \left(\frac{\sum q_i^p * w_{1j}^p}{\sum q_i^p} \right)^{\frac{1}{p}}$$


$$R(d_j, q_{and}) = 1 - \left(\frac{\sum q_i^p * (1 - w_{1j})^p}{\sum q_i^p} \right)^{\frac{1}{p}}$$

Modèle booléen étendu

Traitement de requête (totalement parenthésée)

– Ex : $((a \wedge b) \vee c) \wedge \neg d$

Arbre de requête



Exemple

Consider the query $q = (T_1 \wedge T_2) \vee T_3$.

$$sim(q, d) = \sqrt[p]{\frac{(1 - \sqrt[p]{(\frac{(1-w_1)^p + (1-w_2)^p}{2})})^p + w_3^p}{2}}$$

Modèle booléen étendu

Documents	Les poids des termes W		RSV Booléen classique		RSV booléen étendu	
	t1	t2	t1 ou t2	t1 et t2	t1 ou t2	t1 et t2
D1	1	1	1	1	1	1
D2	1	0	1	0	$1/\text{sqr}(2)$	$1-1/\text{sqr}(2)$
D3	0	1	1	0	$1/\text{sqr}(2)$	$1-1/\text{sqr}(2)$
D4	0	0	0	0	0	0

Modèle booléen basé sur des ensembles flous

Modèle booléen basé sur des ensembles flous

Un document est représenté comme un ensemble de termes pondérés comme suit:

$$\mathbf{d} = \{..., (t_i, a_i), ...\}$$

t_i est le terme, a_i est le poids associé au terme t_i .

Le degré de correspondance (évaluation d'une requête) :

Méthode 1: [Lukaswicz]

$$R(d, t_i) = a_i$$

$$R(d, q_1 \wedge q_2) = R(d, q_1) * R(d, q_2).$$

$$R(d, q_1 \vee q_2) = R(d, q_1) + R(d, q_2) - R(d, q_1) * R(d, q_2).$$

$$R(d, \neg q_1) = 1 - R(d, q_1).$$

Dans les modèles basés sur la logique floue, la pertinence d'un document est exprimée par un score de vérité compris entre 0 et 1, où une valeur proche de 1 indique une forte pertinence, tandis qu'une valeur proche de 0 indique une faible pertinence.

Modèle booléen basé sur des ensembles flous

Un document est représenté comme un ensemble de termes pondérés comme suit:

$$d = \{..., (t_i, a_i), ...\}$$

t_i est le terme, a_i est le poids associé au terme t_i .

Le degré de correspondance (évaluation d'une requête) :

Méthode 2: [Kraft et al.1983]

$$R(d, q_1 \wedge q_2) = \min(R(d, q_1), R(d, q_2)).$$

$$R(d, q_1 \vee q_2) = \max(R(d, q_1), R(d, q_2)).$$

$$R(d, \neg q_1) = 1 - R(d, q_1).$$

Documents	Sim ₁ a			
	a	b	$a \vee b$	$a \wedge b$
D ₁	1	1	1	1
D ₂	0.8	1	1	0.8
D ₃	0	0.5	0.5	0
D ₄	0.8	0	0.8	0

Le Modèle Vectoriel

(VSM: Vector Space Model)

Modèle vectoriel

- Créé au début des années 70 par **Gerard Salton** : système SMART (System for the Mechanical Analysis and Retrieval of Text).
- le modèle **best-match** le plus commun
 - requête en texte libre
 - documents ordonnés dans la réponse
- A l'origine; il concernait les documents textuels puis il est étendu à d'autres types de documents.
- Les documents et la requête sont représentés comme des vecteurs dans un espace vectoriel

Les concepts du Modèle VSM

- **$T = \{t_1, t_2, \dots, t_n\}$** : est l'ensemble des termes d'indexation (termes de la collection des documents).
- L'ensemble $T = \{t_1, t_2, \dots, t_n\}$ appelé **Vocabulaire** est l'ensemble de termes d'indexation du corpus.
- **$D = \{d_1, d_2, \dots, d_n\}$** : est l'ensemble des documents du corpus
- **$Q = \{q_1, q_2, \dots, q_k\}$** : est l'ensemble l'ensemble des requêtes du corpus
- Un document d_i est représenté par un vecteur dont les composantes sont les poids des termes t_j dans le document d_i :

$$d_j = (w_{1,j}, w_{2,j}, \dots, w_{n,j}) \quad \text{avec } j=1 \dots, n$$

- Une requête requête q est représentée par un vecteur dont les composantes sont les poids des termes t_j dans la requête la requête q :

$$q = (w_{1,q}, w_{2,q}, \dots, w_{n,q})$$

Matrice documents termes

- Une collection de documents $D=\{d_1, d_2, \dots, d_m\}$ et un ensemble $T=\{t_1, t_2, \dots, t_n\}$ de termes distincts sont représentés par la matrice documents -termes suivante:

	t_1	t_2	$\dots$	t_n
d_1	w_{11}	w_{12}	$\dots$	w_{1n}
d_2	w_{21}	w_{22}	$\dots$	w_{2n}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
d_m	w_{m1}	w_{m2}	$\dots$	w_{mn}


Matrice requêtes-termes

- Un ensemble de requêtes $Q = \{q_1, q_2, \dots, q_k\}$ et un ensemble $T = \{t_1, t_2, \dots, t_n\}$ de termes distincts sont représentés par la **matrice requêtes-termes** suivante:

	t_1	t_2	$\dots$	t_n
q_1	w_{11}	w_{12}	$\dots$	w_{1n}
q_2	w_{21}	w_{22}	$\dots$	w_{2n}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
q_k	w_{k1}	w_{k2}	$\dots$	w_{kn}

La fonction de correspondance RSV

- L'appariement document-requête dans un modèle vectoriel consiste à trouver les vecteurs **documents** les plus proches du vecteur de la **requête**.
- Cet appariement est obtenu par l'évaluation de la distance entre les 2 vecteurs



La fonction de correspondance RSV

<i>Le produit scalaire :</i>	$RSV(d_i, q) = \sum_{j=1}^n w_{ij} \times w_{qj}$
<i>Distance euclidienne :</i>	$RSV(d_i, q) = \sqrt{\sum_{j=1}^n (w_{ij} - w_{qj})^2}$
<i>La mesure cosinus :</i>	$RSV(d_i, q) = \frac{\vec{d_i} \cdot \vec{q}}{ \vec{d_i} \cdot \vec{q} } = \frac{\sum_{j=1}^n w_{ij} \times w_{qj}}{\sqrt{\sum_{j=1}^n w_{ij}^2} \times \sqrt{\sum_{j=1}^n w_{qj}^2}}$
<i>La mesure de Dice :</i>	$RSV(d_i, q) = \frac{2 \times \sum_{j=1}^n w_{ij} \times w_{qj}}{\sum_{j=1}^n w_{ij}^2 + \sum_{j=1}^n w_{qj}^2}$
<i>La mesure de Jacard :</i>	$RSV(d_i, q) = \frac{\sum_{j=1}^n w_{ij} \times w_{qj}}{\sum_{j=1}^n w_{ij}^2 + \sum_{j=1}^n w_{qj}^2 - \sum_{j=1}^n w_{ij} \times w_{qj}}$
<i>Le coefficient de superposition (overlap) :</i>	$RSV(d_i, q) = \frac{\sum_{j=1}^n w_{ij} \times w_{qj}}{\min(\sum_{j=1}^n w_{ij}^2, \sum_{j=1}^n w_{qj}^2)}$

La similarité cosinus

La similarité cosinus est plus utilisée pour mesurer la proximité des vecteurs dans l'espace vectoriel de dimension n:

$$\text{Sim} (D_i, Q) = \frac{\sum_{k=1}^N (w_{i,k} \cdot w_{q,k})}{\sqrt{\sum_{k=1}^N (w_{i,k})^2 \sum_{k=1}^N (w_{q,k})^2}}$$

Un cosinus plus élevé signifie que l'angle entre les vecteurs est plus petit, ce qui indique une similarité plus élevée.

Exercice d'Application

Soient les 3 documents $d1$, $d2$ et $d3$ représentés dans un VSM:

- $d1=(1,0,1,0,0,0)$

- $d2=(3,0,2,1,0,0)$

- $d3=(1,2,3,0,1,0)$

Soient les 2 requêtes $q1$ et $q2$ représentés dans un VSM:

- $q1=(2,0,2,0,0,0)$

- $q2=(0,0,0,2,0,2)$

1. Représentez la matrice termes-documents
2. Représenter la matrice termes-requêtes.
3. Calculer la similarité RSV (cosinus et distance euclidienne)
4. Quels sont les documents pertinents

Exercice d'Application

1. La matrice termes-documents.

	t_1	t_2	t_3	t_4	t_5	t_6
d_1	1	0	1	0	0	0
d_2	3	0	2	1	0	0
d_3	1	2	3	0	1	0

2. La matrice termes-requêtes.

	t_1	t_2	t_3	t_4	t_5	t_6
q_1	2	0	2	0	0	0
q_2	0	0	0	2	0	2

Exercice d'Application

3. Calculer la similarité.

- Calculer $RSV(d_i, q_1)$ avec la mesure cosinus:

$$RSV(d_1, q_1) = \frac{1*2+1*2}{\sqrt{1^2+1^2}*\sqrt{2^2+2^2}} = \frac{4}{1,414*2,828} = 1$$

$$RSV(d_2, q_1) = \frac{3*2+2*2}{\sqrt{3^2+2^2+1^2}*\sqrt{2^2+2^2}} = \frac{10}{3,741*2,828} = 0,944$$

$$RSV(d_3, q_1) = \frac{1*2+3*2}{\sqrt{1^2+2^2+3^2+1^2}*\sqrt{2^2+2^2}} = \frac{8}{3,87*2,828} = 0,73$$

Interprétations des résultats: Le document d1 a le plus grand cosinus donc répond bien à la requête q1, donc d1 est plus pertinent que les documents d2 et d3.

L'ordre des document selon cosinus : d1,d2,d3.

Exercice d'Application

3. Calculer la similarité.

- Calculer $RSV(d_i, q_2)$ avec la mesure cosinus:

$$RSV(d1, q2) = \frac{0}{\sqrt{1^2+1^2} * \sqrt{2^2+2^2}} = 0$$

$$RSV(d2, q2) = \frac{1*2}{\sqrt{3^2+2^2+1^2} * \sqrt{2^2+2^2}} = \frac{2}{3,741*2,828} = 0,188$$

$$RSV(d3, q2) = \frac{0}{\sqrt{1^2+2^2+3^2+1^2} * \sqrt{2^2+2^2}} = 0$$

Interprétations des résultats: Les documents d1 et d3 ont un cosinus nul donc ne répondent pas à la requête q2, donc d2 est le seul document pertinent.

L'ordre des document selon cosinus : d2,d1,d3 ou d2,d3,d2

Exercice d'Application

3. Calculer la similarité.

- Calculer $RSV(d_i, q_1)$ avec la distance euclidienne:

$$RSV(d1, q1) = \sqrt{\sum_{j=1}^6 (w_{ij} - w_{qj})^2} = \sqrt{(1-2)^2 + (1-2)^2} = \sqrt{1+1} = 1,414$$

$$RSV(d2, q1) = \sqrt{\sum_{j=1}^6 (w_{ij} - w_{qj})^2} = \sqrt{(3-2)^2 + (2-2)^2 + (1-0)^2} = \sqrt{1+1} = 1,414$$

$$RSV(d3, q1) = \sqrt{\sum_{j=1}^6 (w_{ij} - w_{qj})^2} = \sqrt{(1-2)^2 + (2-0)^2 + (3-2)^2 + (1-0)^2} = \sqrt{1+4+1+1} = \sqrt{7} = 2,645$$

Interprétations des résultats: Les documents d1 et d2 sont proches au vecteur requête q1 que le vecteur document d3. donc d1 et d2 répondent mieux à la requête. d1 et d2 sont plus pertinents que d3.

L'ordre des documents selon distance euclidienne : d1,d2,d3 ou d2,d1,d3. (ordre croissant)

Exercice d'Application

3. Calculer la similarité.

- Calculer $RSV(d_i, q_2)$ avec la distance euclidienne:

$$RSV(d1, q2) = \sqrt{\sum_{j=1}^6 (w_{ij} - w_{qj})^2} = \sqrt{(1-0)^2 + (1-0)^2 + (0-2)^2 + (0-2)^2} = \sqrt{1+1+4+4} = \sqrt{10} = 3,162$$

$$RSV(d2, q2) = \sqrt{\sum_{j=1}^6 (w_{ij} - w_{qj})^2} = \sqrt{(3-0)^2 + (2-0)^2 + (1-2)^2 + (0-2)^2} = \sqrt{9+4+1+4} = \sqrt{18} = 4,242$$

$$RSV(d3, q2) = \sqrt{\sum_{j=1}^6 (w_{ij} - w_{qj})^2} = \sqrt{(1-0)^2 + (2-0)^2 + (3-0)^2 + (0-2)^2 + (1-0)^2 + (0-2)^2} = \sqrt{1+4+9+4+1+4} = \sqrt{23} = 4,795$$

Interprétations des résultats: Les documents d1 est plus proche au vecteur requête q2 que les vecteurs documents les vecteurs documents d2 puis d3. donc d1 répond mieux à la requête. d1 est plus pertinent que d2 et d3.

L'ordre des documents selon distance euclidienne : d1,d2,d3. (ordre croissant)