

Techniques d'indexation et recherche multimedia



Dr. Anwer KALGHOUM
anwer.kalghoum@gmail.com
Département Informatique

Plan du cours

- **Chapitre 1** : Les notions de bases de la recherche d'information
- **Chapitre 2** : Les modèles de recherche d'information
- **Chapitre 3** : Evaluation des systèmes de recherche d'information

- **Recherche d'information** (RI) est une branche de l'informatique qui s'intéresse à l'acquisition, l'organisation, le stockage, la recherche et la sélection d'information «salton1968»
- Ensemble des **méthodes et techniques** pour l'acquisition, l'organisation, le stockage, la recherche et **la sélection d'information pertinente pour un utilisateur.**



Google

bing

YAHOO!

Andex
SOLUTIONS INC.

NAVER

Baidu 百度


- Plusieurs domaines d'application
 - Internet (Web, Forum/Blog search, news)
 - Entreprises (entreprise search)
 - Bibliothèques numériques «digital library»
 - Domaine spécialisé (médecine, droit, littérature, chimie, mathématique, brevets, software, ...)
 - Nos propres PC (Yahoo! Desktop search)

40 000 Hexbytes = 42 949 672 960 000 GigaBytes = quarante-deux **billions** GigaBytes

<i>KiloOctets</i>	10^3
<i>MegaOctets</i>	10^6
<i>GigaOctets</i>	10^9
<i>TeraOctets</i>	10^{12}
<i>PetaOctets</i>	10^{15}
<i>ExaOctets</i>	10^{18}
<i>ZettaOctets</i>	10^{21}

**Facteur de 10 en
5 ans!**








- L'information (numérique) est disponible partout et avec un gros volumes.
- Création des systèmes de recherche d'information.

- Un **Système de Recherche d'Information (SRI)** est un programme (ensemble de programmes) informatique qui a pour but de **sélectionner** des **informations pertinentes** répondant à des **besoins utilisateurs**



Critère	Système de base de données (SGBD)	Système de recherche d'information (SRI)
Objectif principal	Stocker, gérer et interroger des données structurées	Retrouver des documents ou informations pertinentes
Type de données	Données structurées (tables, lignes, colonnes)	Données non structurées (textes, documents, pages web)
Modèle de données	Relationnel, objet, NoSQL	Modèle vectoriel, booléen, probabiliste
Langage de requête	SQL	Mots-clés, requêtes textuelles
Résultat des requêtes	Résultats exactes et complètes	Résultats pertinents, souvent classés

Système de gestion de Base de données

Données :

Chaîne de caractères + valeurs
associées à des objets, des
personnes et des événements :
température : (15)
- **Select .. From ... where**

Système de Recherche d'information

Information :

Signification (explication/
description) des données, données
intelligible (compréhensible):
température à el Kef =
(0° C - à 18 h,
, à El Kef)

Texte : Des articles, blogs, essais, rapports, nouvelles, et bien d'autres formes de contenu écrit.

Images : Des photos, infographies, illustrations, graphiques, et autres éléments visuels.

Vidéos : Des clips, tutoriels, documentaires, émissions, et vidéos de divertissement.

Audio : Podcasts, émissions de radio en ligne, fichiers musicaux, et enregistrements audio.

Réseaux sociaux : Informations partagées sur des plateformes telles que Facebook, Twitter, Instagram, LinkedIn, etc.

Données scientifiques : Recherches académiques, publications scientifiques, données expérimentales.

E-books et livres électroniques : Une variété de livres numériques sur divers sujets.

Cartes et géographie : Informations cartographiques, images satellite, données géographiques.

Forums et discussions en ligne : Conversations sur des sujets variés, échanges d'expériences et de conseils.


E-commerce : Des informations sur les produits, les services, les prix, les avis de consommateurs.

Actualités : Les dernières nouvelles nationales et internationales.

Enseignement en ligne : Cours, tutoriels, ressources pédagogiques.

Données météorologiques : Prévisions météorologiques, conditions actuelles.

Données financières : Cours des actions, taux de change, informations économiques.



- Sélectionner dans une collection
 - les informations (items, documents, ..)
 - ... pertinentes répondant aux
 - ... besoins en information des utilisateurs

La Recherche d'Information (RI) présente plusieurs problématiques importantes.


- **La pertinence:** Identifier et récupérer les informations pertinentes parmi une quantité énorme de données disponibles sur le web ou dans les bases de données.
- **La précision:** Assurer que les résultats de la recherche sont précis et fiables, en évitant les informations trompeuses ou erronées.
- **La sémantique:** Comprendre le sens des requêtes de recherche et des documents, en tenant compte du contexte linguistique pour améliorer la pertinence des résultats.

La notion de pertinence peut être analysée à deux niveaux :

□ **Niveau utilisateur :** la pertinence correspond à la satisfaction de l'utilisateur par rapport à l'ensemble des documents restitués par le SRI.

□ **Niveau système :** le système mesure un degré de pertinence, une valeur de similitude entre un document et une requête.

Le but de tout SRI est de rapprocher la pertinence système de la pertinence utilisateur.



- **Indexation** = représentation de l'information

Def1: Elle consiste à créer un ensemble de mots-clés reflétant au mieux **le contenu sémantique du document** ; cette liste de mots-clés sera plus facilement exploitable lors du processus de recherche d'information (RI).

Def2 : Processus permettant de construire un ensemble d'éléments « clés » permettant de caractériser le contenu d'un document.


- **Éléments clés**

- Information textuelle
 - mots simples : pomme
 - groupe de mots : pomme de terre
- Image
 - Couleurs, formes

- **Les approches d'indexation**

- ✓ Manuelle (expert en indexation)
- ✓ Automatique (ordinateur)
- ✓ Semi-automatique (combinaison des deux)

- ❑ Choix des mots effectué par des indexeurs
- ❑ Basée sur un vocabulaire contrôlé
- ❑ Approche utilisée souvent dans les bibliothèques, les centres de documentation
- ❑ Dépend du savoir faire de l'indexeur



Imaginons une bibliothèque universitaire qui souhaite indexer manuellement ses livres pour faciliter la recherche des étudiants. Les bibliothécaires effectuent l'indexation manuelle en suivant ces étapes :

- **Analyse du contenu**: Un bibliothécaire prend un livre et examine son contenu pour en comprendre le sujet, les thèmes abordés, et les concepts principaux.
- **Attribution de mots-clés** : En se basant sur leur compréhension du livre, les bibliothécaires sélectionnent des mots-clés pertinents qui représentent le contenu du livre. Par exemple, pour un livre sur l'histoire de la Révolution française, les mots-clés pourraient inclure "Révolution française", "France", "histoire", "révolte", etc.
- **Classification** : Le livre est ensuite classé dans une catégorie appropriée, telle que "Histoire", "Révolution", "Informatique", etc. Cette classification aide à organiser les livres de manière logique dans la bibliothèque et à faciliter la recherche des étudiants.
- **Étiquetage** : Le livre est étiqueté avec des métadonnées telles que l'auteur, le titre, la date de publication, et d'autres informations pertinentes.

Avantage du vocabulaire contrôle

- Permet la recherche par concepts (par sujets, par thèmes).
- Permet la classification (regroupement) de documents (par sujets, par thème)
- Fournit une terminologie standard pour indexer et rechercher les documents

Inconvénients du vocabulaire contrôlé

- ❑ **Indexation très coûteuse**
 - Pour construire le vocabulaire
 - Pour affecter les concepts (termes) aux documents (**imaginer cette opération sur le web**)
- ❑ **Difficile à maintenir**
 - La terminologie évolue, plusieurs termes sont rajoutés tous les jours
- ❑ **Processus humain donc subjectif**
 - Des termes différents peuvent être affectés à un même document par des indexeurs différents
- ❑ **Les utilisateurs ne connaissent pas forcément le vocabulaire utilisé par les indexeurs**

C'est le SRI qui génère les indexes des documents.

Approches :

- ❖ **Statistique** (distribution des mots) et/ou **TALN** (Traitement automatique du langage naturel | compréhension du texte)

→ Approche courante est plutôt statistique avec des hypothèses simples :

□ Redondance d'un mot marque son importance

□

4 étapes :

- Étape 1 : Extraction de mots simples
- Étape 2 : Normalisation des mots extraits
- Étape 3 : Statistique sur les occurrences
- Étape 4: Construction du fichier inverse et pondération des mots

Etape 1 : Extraction des mots

1. Extraire les termes (Ségmentation - tokenization)

terme = suite de caractères séparés par (blanc ou signe de ponctuation, caractères spéciaux,...), Nombres

☐ Ce sont les index utilisés lors de la recherche

2. Suppression des mots « vides »

Mots trop fréquents mais pas utiles

– **Exemples :**

- **Anglais :** the, or, a, you, I, us, ...
- **Français :** le , la de , des, je, tu, ...

Etape 2 : Normalisation des mots extraits

□ Stemming

- Processus morphologique permettant de regrouper les variantes d'un mot
- Ex1 : économie, économiquement, économiste, $\Rightarrow$ **économ**
- Ex2 (pour l'anglais) : CONNECTED, CONNECTION, CONNECTING $\rightarrow$ CONNECT

□ Utilisation de règles de transformations

- **règle de type** : condition action :

Ex : si mot se termine par s supprimer la terminaison

- Technique utilisée principalement pour l'anglais :

L'algorithme le plus connu est : **Porter for anglais, stemming for french and arab**

Etape 2 : Normalisation des mots extraits ave Porter

- Step 1: plurals and past participles
 - SSES -> SS caresses -> caress
 - (*v*) ING -> motoring -> motor
- Step 2: adj->n, n->v, n->adj, ...
 - (m>0) OUSNESS -> OUS callousness -> callous
 - (m>0) ATIONAL -> ATE relational -> relate
- Step 3:
 - (m>0) ICATE -> IC triplicate -> triplic
- Step 4:
 - (m>1) AL -> revival -> reviv
 - (m>1) ANCE -> allowance -> allow
- Step 5:
 - (m>1) E -> probate -> probat
 - (m > 1 and *d and *L) -> single letter controll -> control

Etape 2 : Normalisation des mots extraits

□ Analyse grammaticale

- Utilisation de lexique (dictionnaire)

□ Troncature : Tronquer les mots à X caractères

- Tronquer plutôt les suffixes
- Exemple troncature à 7 caractères : économiquement : écomoni

Quelle est la valeur optimale de X ? : 7 caractères pour le Français

Etape 3 : Statistique sur les occurrences

Pour chaque mot, on doit faire la statistique de sa fréquence d'occurrence dans le document. Ainsi, à chaque nouvelle occurrence d'un mot, on ajoute 1 dans sa fréquence.

(Exemple)

- ✓ **Texte** : un système de recherche d'informations (document) (SRI, base de données documentaires) permet d'analyser, d'indexer et de retrouver les documents pertinents répondant à un besoin d'un utilisateur.

Etape 1 : Extraire les termes et suppression des mots vides

- ✓ système, recherche, informations, document, SRI, base, données, documentaires, analyser, indexer, retrouver, documents, pertinents, répondant, besoin, utilisateur

Etape 2 : Normalisation des mots extraits (troncature à 7)

- ✓ systeme, recherc, informa, documen, sri, base, donnee, documen, analyse, indexer, retrouv, documen, pertine, reponda, besoin, utilisa

Etape 3 : Statistique sur les occurrences

- ✓ systeme 1, recherc 1, informa 1, documen 3, sri 1, base 1, donnee 1, analyse1, indexer 1, retrouv 1, pertine 1, reponda 1, besoin 1, utilisa 1

Etape 4 : Construction du fichier inverse et pondération des mots

Une fois les documents indexés le résultat est que chaque document aura donc un **descripteur** / **une représentation** :

□ Un descripteur :

- Liste de mots
- Fréquence de chaque mot

□ Ces mots sont ensuite stockés dans une structure appelée **fichier inverse**

Etape 4 : Construction du fichier inverse et pondération des mots

Doc 1

I did enact Julius
Caesar I was killed
i' the Capitol;
Brutus killed me.

Doc 2

So let it be with
Caesar. The noble
Brutus hath told you
Caesar was ambitious

Term	Doc #
I	1
did	1
enact	1
julius	1
caesar	1
I	1
was	1
killed	1
i'	1
the	1
capitol	1
brutus	1
killed	1
me	1
so	2
let	2
it	2
be	2
with	2
caesar	2
the	2
noble	2
brutus	2
hath	2
told	2
you	2
caesar	2
was	2
ambitious	2

Etape 4 : Construction du fichier inverse et pondération des mots

Doc 1

I did enact Julius
Caesar I was killed
i' the Capitol;
Brutus killed me.


Doc 2

So let it be with
Caesar. The noble
Brutus hath told you
Caesar was ambitious

term	docID	term	docID
I	1	ambitious	2
did	1	be	2
enact	1	brutus	1
julius	1	brutus	2
caesar	1	capitol	1
I	1	caesar	1
was	1	caesar	2
killed	1	caesar	2
i'	1	did	1
the	1	enact	1
capitol	1	hath	1
brutus	1	I	1
killed	1	I	1
me	1	i'	1
so	2	it	2
let	2	julius	1
it	2	killed	1
be	2	killed	1
with	2	let	2
caesar	2	me	1
the	2	noble	2
noble	2	so	2
brutus	2	the	1
hath	2	the	2
told	2	told	2
you	2	you	2
caesar	2	was	1
was	2	was	2
ambitious	2	with	2

term	doc. freq.	→	postings lists
ambitious	1	→	2
be	1	→	2
brutus	2	→	1 → 2
capitol	1	→	1
caesar	2	→	1 → 2
did	1	→	1
enact	1	→	1
hath	1	→	2
I	1	→	1
i'	1	→	1
it	1	→	2
julius	1	→	1
killed	1	→	1
let	1	→	2
me	1	→	1
noble	1	→	2
so	1	→	2
the	2	→	1 → 2
told	1	→	2
you	1	→	2
was	2	→	1 → 2
with	1	→	2

Etape 4 : Construction du fichier inverse et pondération des mots



Etape 4 : pondération des mots

Comment caractériser les termes importants dans un document ou plusieurs documents?

-Pondération des termes
- Idée :
 - Les termes importants doivent avoir un poids fort

- **Plusieurs approches :**

- **Tf, IDF** (approche plus répandue)
- Pourvoir discriminatoire d'un terme
-

- **Dépend aussi du modèle de RI.**

□ **TF** : (*term frequency*) plus un terme est fréquent dans un document plus il est important dans la description de ce document

Variantes de TF

Schéma de pondération	formule du TF
binaire	0, 1
nombre d'occurrences	$f_{t,d}$
fréquence brute	$f_{t,d} / \sum_{t' \in d} f_{t',d}$
normalisation logarithmique	$\log(1 + f_{t,d})$

La fréquence « brute » d'un terme est simplement le nombre d'occurrences de ce terme dans le document considéré, divisé par le nombre de mots du document. On peut choisir cette fréquence brute pour exprimer la fréquence d'un terme.

TF(t) = Nombre d'apparitions du terme t dans le document / Nombre total de mots dans le document

Exemple : TF avec La fréquence « brute »

$TF(t) = \text{Nombre d'apparitions du terme } t \text{ dans le document} / \text{Nombre total de mots dans le document}$

Le nombre d'occurrence du terme « contraste » dans le document 2 égale 1. donc, la fréquence du terme « contraste » égale $1/5 \approx 0,2$.

Document 1
même dans tout l'Orient

Document 2
Le contraste entre l'Orient

mot	docID
même	1
dans	1
tout	1
l'	1
Orient	1
le	2
contraste	2
entre	2
l'	2
Orient	2

	contraste	dans	entre	le	l'	même	orient	tout
Document 1	0	0,2	0	0	0,2	0,2	0,2	0,2
Document 2	0,2	0	0,2	0,2	0,2	0	0,2	0

□ **IDF** : (Inverse Document Frequency) la fréquence du terme dans la collection (ensemble des documents).

$$\text{idf}_1 = \log \frac{|D|}{|\{d_j : t_1 \in d_j\}|}$$

où :

- $|D|$: nombre total de documents dans le corpus ;
- $|\{d_j : t_i \in d_j\}|$: nombre de documents où le terme t_i apparaît (c'est-à-dire $n_{i,j} \neq 0$).

□ **Le poids du terme dans un document**

$$w(t, d) = tf * idf$$

□ **IDF** : (Inverse Document Frequency) la fréquence du terme dans la collection (ensemble des documents).

Document 1
même dans tout l'Orient

Document 2
Le contraste entre l'Orient

Le nombre total de segments est $|D| = 2$. Maintenant nous calculons les fréquences inverses de segments. Par exemple, le terme « contraste » apparaît une seule fois dans le segment 1, dans ce cas, la valeur idf sera : $idf = \log \frac{2}{1}$. Ainsi, le tableau suivant illustre les valeurs idf pour chaque terme.

Terme	contraste	dans	entre	le	l'	même	orient	tout
IDF	$\log(2/1) \approx 0.301$	$\log(2/1) \approx 0.301$	$\log(2/1) \approx 0.301$	$\log(2/1) \approx 0.301$	$\log(2/2) \approx 0$	$\log(2/1) \approx 0.301$	$\log(2/2) \approx 0$	$\log(2/1) \approx 0.301$

□ Le poids du terme dans un document = **TF * IDF**

Document 1
même dans tout l'Orient

Document 2
Le contraste entre l'Orient

Le tableau suivant illustre les valeurs de $TF * IDF$ pour chaque segment.

Terme	contraste	dans	entre	le	l'	même	orient	tout
Doc1	$0 * 0.301 = 0$	$0.2 * 0.301 = 0.602$	$0 * 0.301 = 0$	$0 * 0.301 = 0$	$0.2 * 0 = 0$	$0.2 * 0.301 = 0.602$	$0.2 * 0 = 0$	$0.2 * 0.301 = 0.602$
Doc2	$0.2 * 0.301 = 0.602$	$0 * 0.301 = 0$	$0.2 * 0.301 = 0.602$	$0.2 * 0.301 = 0.602$	$0.2 * 0 = 0$	$0 * 0.301 = 0$	$0.2 * 0 = 0$	$0 * 0.301 = 0$

Document 1 : "Le serveur distant analyse les requêtes HTTP pour vérifier la validité des certificats SSL avant d'établir une connexion sécurisée."

Document 2 : "L'application mobile synchronise régulièrement les données de l'utilisateur avec la base de données en ligne afin de garantir une expérience fluide et en temps réel."

Document 3 : "Le programme de détection des intrusions utilise une combinaison d'algorithmes de machine learning et de signatures pour identifier et bloquer les attaques réseau en temps réel."

1. Construire le fichier inverse
2. Calculer la TF et l'IDF pour chaque terme dans ces documents.
3. Calculer le poids $w(t, d)$ pour chaque terme dans ces documents.

- **Français:** {à, au, avec, ce, ces, dans, de, des, du, elle, en, et, il, je, tu, nous, vous, la, le, les, l', d', un, une, pour ...}

- **Anglais:** {the, and, of, to, a, in, that, is, was, he, for, it, with, as, on, be, by, this, not, or, I, you, ...}

1.